

Zadanie 6 - Liczby pierwsze - CUDA

Celem zadania było przetestowanie czy liczby podane w pliku są liczbami pierwszymi. W celu poprawy wydajności obliczeń program należało zrównoleglić z użyciem technologii CUDA.

Program przyjmuje na wejściu jeden argument: ścieżkę do pliku w którym znajduje się lista liczb do przetestowania. Pierwszą rzeczą jaką wykonuje program jest sprawdzenie czy została podana odpowiednia ilość argumentów. Następnie zostaje wczytany plik a wpisane liczby umieszczone są w tablicy.

```
1 __global__ void calculate( ll *Arr, bool *results, int sizeofArray, int
  amountOfBlocks){
2
3     int x = (blockIdx.x * blockDim.x) + threadIdx.x;
4
5     if (amountOfBlocks >= sizeofArray){
6         results[x] += isPrime(Arr[x]);
7     } else{
8         int sizeofPart = sizeofArray / amountOfBlocks;
9         int restOfDivide = sizeofArray%amountOfBlocks;
10
11         int startPart = sizeofPart * x;
12         int endPart = sizeofPart * (x + 1);
13
14         if (endPart <= sizeofArray)
15         {
16             int restStart = sizeofPart * amountOfBlocks;
17
18             for (int i = startPart; i < endPart; i++){
19                 results[i] += isPrime(Arr[i]);
20             }
21
22             if (x < restOfDivide){
23                 results[restStart + x] += isPrime(Arr[restStart + x]);
24             }
25
26         }
27     }
28 }
29 }
```

Powyższy funkcja jest wywoływana z hosta i odpowiada za odpowiedni podział przesłanej tablicy z liczbami do sprawdzenia. Dzięki zmiennym dostępnym w architekturze CUDA blockIdx.x, blockDim.x oraz threadIdx.x obliczany jest unikalny indeks bloku. Następnie jeżeli liczba bloków jest większa lub równa ilości liczb w tablicy w każdym bloku jest obliczana pojedyncza liczba. W przeciwnym wypadku tablica jest rozdzielana na równe części między bloki i poszczególne oszacowanie jest przeprowadzane na tych partiach tablicy liczb.

```
1 __device__ bool isPrime( ll n)
2 {
3     if(n<2)
4         return false;
```

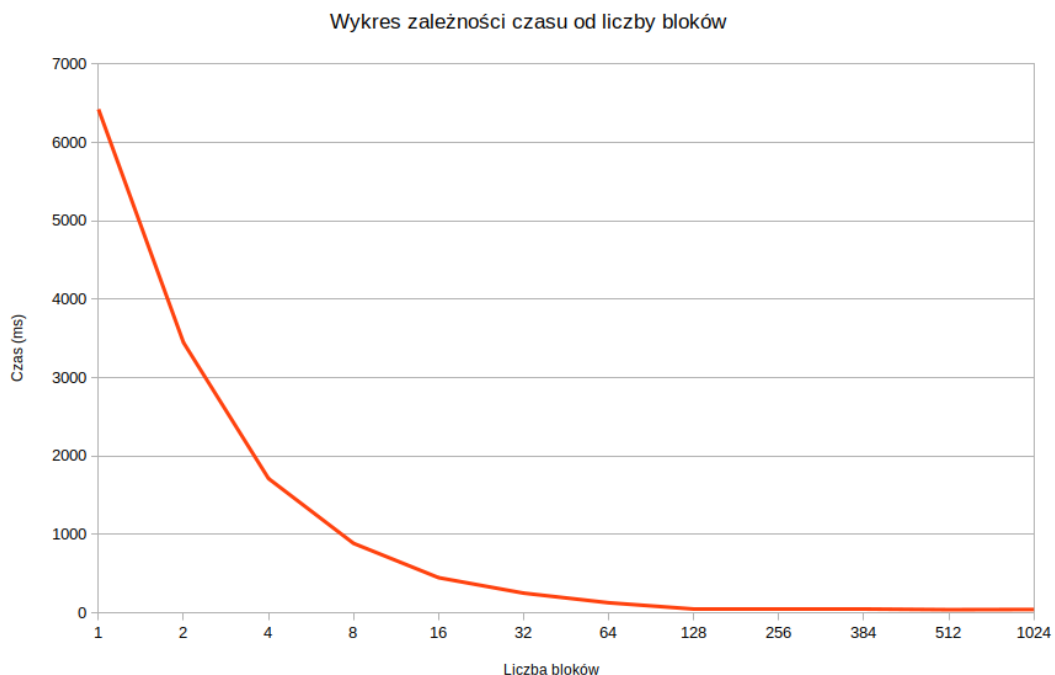
```

5
6     for (ll i=2; i*i<=n; i++)
7         if (n%i==0)
8             return false;
9
10    return true;
11 }

```

Powyższy listing przedstawia algorytm wyznaczania liczby pierwszej. Funkcja zostaje uruchomiona na urządzeniu z funkcji już działającej również na urządzeniu, dlatego przed zwracaniem typu pojawiło się słowo kluczowe `__device__`. Został wybrany algorytm naiwny, ponieważ gwarantował poprawność wyników, a ilość i długość testowanych liczb nie była na tyle długa by powodowało to znaczące obniżenie wydajności obliczeń. Powyższy kod zostaje wywołany dla oszacowania każdej liczby znajdującej się w tablicy.

Poniższy wykres przedstawia wyniki uzyskane na serwerze CUDA. Czas obliczeń dla każdej ilości bloków przedstawionej na wykresie został przetestowany 5 razy a z wyników wyciągnięto średnią arytmetyczną.



Rysunek 1: Wykres zależności czasu wykonywania obliczeń od liczby bloków

Jak można zauważyć, czas obliczeń znacząco się zmniejsza wraz z rozpoczęciem zwiększania liczby bloków. Wraz z wzrostem liczby bloków różnice pomiędzy sąsiednimi czasami stają się coraz mniejsze. Siatka została ustawiona na wartość 1 gdyż taka konfiguracja dawała najlepsze rezultaty. Liczba bloków na jakich program uzyskuje najlepsze rezultaty zależy od ilości liczb do przetestowania. W naszym przypadku dla zbioru testowego składającego się z 500 liczb, liczba bloków powyżej tej wartości nie dawała przyspieszenia, gdyż każda liczba zostawała przypisana do jednego bloku. Dlatego też końcowy ilość bloków jest ustalana na podstawie ilości liczb zawartych w testowym pliku i jest ustalana podczas uruchomienia programu. Jest to rozwiązanie optymalne dla naszego algorytmu. W kernelu odbywa się podział liczb między bloki oraz wyznaczanie czy przesłana liczba jest liczbą pierwszą.